

[5] MEDIDAS DE DISPERSÃO E ASSIMETRIA

***PALAVRAS-CHAVE:** Desvio-padrão, Coeficiente de variação, Assimetria*

MEDIDAS DE DISPERSÃO

- *Medidas de tendência central* – dão informações sobre o centro de uma distribuição
- *Medidas de dispersão* – dão informações quanto à variabilidade e flutuação dos dados, ou seja, sobre “quanto” se dispersam os dados e “quanto” estão espalhados em torno de um centro

Exemplo 1

- Classificações do serviço de *room service* (realizadas pelos clientes) do hotel *stay@Peniche*: 7, 8 e 14 - Média = 10
- Classificações do serviço de *room service* (realizadas pelos clientes) do hotel *out@Peniche*: 10, 10 e 11 - Média = 10

MEDIDAS DE DISPERSÃO

- VERIFICAR A **REPRESENTATIVIDADE DAS MEDIDAS DE LOCALIZAÇÃO** (pois é muito comum encontrarmos variáveis que, apesar de terem a **mesma média**, são **compostas de valores bem distintos**)
- Indicam-nos o **GRAU DE CONCENTRAÇÃO** dos valores observados
- As medidas de dispersão podem ser divididas em categorias:

Medidas de distância, cujos valores se apresentam na mesma unidade de medida dos dados originais e não recorrem ao cálculo prévio de uma medida de localização.

intervalo de variação ou amplitude e o intervalo interquartis

Comparação, utilizam uma medida de localização para efectuar a comparação.

variância, desvio-padrão e erro-padrão da média

Medidas relativas à média

coeficiente de variação e dispersão

MEDIDAS DE DISPERSÃO

DISPERSÃO

Amplitude (*range*) [R]

Distância inter-quartil (*inter-quartile range*) [IQ]

Variância (*variance*) [S^2]

Desvio-padrão (*standard deviation*) [S]

Erro-padrão da média (*standard error of the mean*) [SEM]

Coeficiente de variação (*coefficient of variation*) [CV]

MEDIDAS DE DISPERSÃO :: R

AMPLITUDE DE UM CONJUNTO DE DADOS [R]

Duas das medidas da variabilidade de um conjunto de dados são a **amplitude** e a **amplitude inter-quartil**.

O que é AMPLITUDE?

Chama-se **amplitude** e representa-se por R (Range) de um conjunto de dados, $x_1, x_2, \dots, x_i, \dots, x_n$, à diferença entre o máximo e o mínimo do conjunto de dados.

Se os **dados estão agrupados** em classes, faz-se uma estimativa para a amplitude calculando a diferença entre o limite superior da última classe e o limite inferior da primeira.

MEDIDAS DE DISPERSÃO :: R

AMPLITUDE [R]

- * A amplitude de uma amostra é a diferença entre o máximo e o mínimo.

Exemplo: Na amostra

1.2; 1.7; 2.1; 2.2; 2.3

a amplitude é

$$2.3 - 1.2 = 1.1$$

Desvantagens:

- * Apenas tem em conta os dois valores extremos que a variável toma
- * Não é sensível aos valores intermédios
- * Sensível a valores extremos (claro!)

MEDIDAS DE DISPERSÃO :: IQ

AMPLITUDE INTER-QUARTIL [IQ]

O que é AMPLITUDE INTER-QUARTIL?

A amplitude inter-quartil (IQ) é outra medida de variabilidade para além da amplitude amostral (R) .

Ao contrário da amplitude, a amplitude **IQ** é uma medida resistente → definida à custa de medidas resistentes que são os quartis Q1 e Q3

Ou seja, é representada pela **diferença entre o 3.º e o 1.º quartil.**

MEDIDAS DE DISPERSÃO :: IQ

AMPLITUDE INTER-QUARTIL [IQ]

$$IQ = Q_3 - Q_1$$

No intervalo que entre Q_1 a Q_3 encontram-se 50% das observações (as mais centrais)

Desvantagem:

Não é influenciado por metade dos valores observados e que são valores extremos.

MEDIDAS DE DISPERSÃO :: IQ

AMPLITUDE INTER-QUARTIL [IQ]

Propriedades

Uma amplitude interquartis nula não significa que não exista variabilidade.

5	6	7	7	7	7	7	7	7	7	10
		↓			↓			↓		
		Q_1			Q_2			Q_3		
									$Q_3 - Q_1 = 0$	

Se as observações forem todas iguais, então a amplitude interquartis é igual a zero.

7	7	7	7	7	7	7	7	7	7	7
		↓			↓			↓		
		Q_1			Q_2			Q_3		
									$Q_3 - Q_1 = 0$	

A amplitude interquartis será tanto maior quanto maior variabilidade se verificar entre os dados.

MEDIDAS DE DISPERSÃO :: S²

VARIÂNCIA [s^2 ou σ^2]

A variância é a **média dos quadrados dos desvios das observações em relação à média da amostra**.

(Desvio em relação à média é a diferença entre cada dado da amostra e a média do conjunto de dados da amostra)

Existem duas expressões para representar a variância:

Amostrai s^2

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

ou

$$s'^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

*Quando se trabalha com amostras de pequena dimensão ($n < 30$) utiliza-se a **VARIÂNCIA CORRIGIDA, s'^2***

Populacional σ^2

$$\sigma^2 = \frac{\sum (x - \bar{x})^2}{N}$$

MEDIDAS DE DISPERSÃO :: S²

VARIÂNCIA [s^2 ou σ^2]

▫ *Dados isolados :*

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

ou

$$s'^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

▫ *Dados tabelados :*

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \times F_i}{n}$$

ou

$$s'^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \times F_i}{n-1}$$

▫ *Dados em classes :*

$$s^2 = \frac{\sum_{i=1}^n (c_i - \bar{x})^2 \times F_i}{n}$$

ou

$$s'^2 = \frac{\sum_{i=1}^n (c_i - \bar{x})^2 \times F_i}{n-1}$$

Quando se trabalha com amostras de pequena dimensão ($n < 30$) utiliza-se a **VARIÂNCIA CORRIGIDA, s'^2**

MEDIDAS DE DISPERSÃO :: S^2

VARIÂNCIA [s^2 ou σ^2]

A interpretação do significado da variância, em situações concretas, levanta problemas.

A variância não vem representada na mesma unidade das observações.

Por exemplo:

se estivermos a estudar o tempo (minutos) que um grupo de turistas demora a fazer o check-in num hotel, a média do tempo ainda se exprime em minutos, mas a variância exprime-se em “*minutos²*”?!

MEDIDAS DE DISPERSÃO :: S

DESVIO-PADRÃO [*s* ou σ]

- * Se tomarmos a raiz quadrada da variância obtemos o desvio-padrão que também é uma **medida de dispersão** e vem na mesma unidade das observações.

Amostral s

$$s = \sqrt{\frac{\sum (x - \bar{x})^2}{n}}$$

ou $\sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$

Populacional σ

$$\sigma = \sqrt{\frac{\sum (x - \bar{x})^2}{N}}$$

MEDIDAS DE DISPERSÃO :: S


DESVIO-PADRÃO [s ou σ]

- * O **DESVIO-PADRÃO** (e a variância) podem ser fortemente afectados por erros ou observações muito afastadas (em distribuições muito assimétricas deve-se evitar usá-la)
- * **MEDIDA DE DISPERSÃO POR EXCELÊNCIA**
- * Tem a vantagem, em relação à variância de ter a **MESMA UNIDADE DA VARIÁVEL**
- * É um **CONCEITO IMPRESCINDÍVEL** para análises gráficas, determinação de **confiabilidade** e estudos de distribuições.

MEDIDAS DE DISPERSÃO :: S

VARIÂNCIA [s^2 ou σ^2] **OU DESVIO-PADRÃO** [s ou σ] → **VARIABILIDADE**

Graficamente tem-se:





EXERCÍCIO 1A

Nº de viagens (x_i)	Nº de pessoas (F_i)
0	36
1	79
2	85
3	49
4	16
5	23
6	12

Uma empresa do ramo do turismo pretende estudar o número de vezes por ano que os portugueses viajam para fora de Portugal em lazer. Para esse efeito inquiriu 300 pessoas escolhidas aleatoriamente e organizou os dados obtidos na tabela apresentada.

Amplitude amostral?

Amplitude interquartil?

Variância?

Desvio-Padrão?

Nota:

$$\bar{x} = 2,157$$

$$Q_1 = 1$$

$$Q_3 = 3$$



EXERCÍCIO 2A

Um parque temático está a estudar o tempo de espera dos visitantes na compra de bilhete. Foram registados os dados seguintes:

Tempo (em minutos)	Nº de visitantes
[2,4[	20
[4, 6[	40
[6, 8[	70
[8,10[	90
[10,12]	110

Amplitude amostral?

Amplitude interquartil?

Variância?

Desvio-Padrão?

MEDIDAS DE DISPERSÃO :: CV

COEFICIENTE DE VARIAÇÃO [CV]

Medida de dispersão relativa, útil para a compreensão, em termos relativos, do grau de concentração em torno das médias (*trata-se de uma medida relativa de dispersão e por isso não tem unidades*)

Dado em termos percentuais entre o desvio-padrão e a média da distribuição:

$$CV = \frac{s}{\bar{x}} \times 100 \quad (\%)$$

MEDIDAS DE DISPERSÃO :: CV

COEFICIENTE DE VARIAÇÃO [CV]


O coeficiente de dispersão (ou variação) de uma distribuição relaciona a variabilidade com a média.

Um *CV* superior a 50% indica uma grande dispersão relativa e uma pequena representatividade da média como medida estatística.

Para valores do *CV* inferiores a 50% a média será tanto mais representativa quanto menor o valor deste coeficiente.

Quanto mais baixo, menor o risco!

Só deve ser calculado para variáveis com todos os valores positivos (i.e. ter a garantia que a média >0)



EXERCÍCIO 1B

Nº de viagens (x_i)	Nº de pessoas (F_i)
0	36
1	79
2	85
3	49
4	16
5	23
6	12

Uma empresa do ramo do turismo pretende estudar o número de vezes por ano que os portugueses viajam para fora de Portugal em lazer. Para esse efeito inquiriu 300 pessoas escolhidas aleatoriamente e organizou os dados obtidos na tabela apresentada.

Coeficiente de Variação?



EXERCÍCIO 2B

Um parque temático está a estudar o tempo de espera dos visitantes na compra de bilhete. Foram registados os dados seguintes:

Tempo (em minutos)	Nº de visitantes
[2,4[	20
[4, 6[	40
[6, 8[	70
[8,10[	90
[10,12]	110

Coeficiente de Variação?



EXERCÍCIO 2B

			Cálculos auxiliares para o cálculo da média:			Cálculos auxiliares para o cálculo do desvio-padrão:		
centro da classe (Ci)	Tempo (em minutos)	Nº de visitantes (Fi)	Ci x Fi			Ci - média	(Ci - média) ²	(Ci - média) ² x Fi
3	[2 4 [	20	60			-5,39	29,09	581,89
5	[4 6 [	40	200			-3,39	11,52	460,75
7	[6 8 [	70	490			-1,39	1,94	136,01
9	[8 10 [	90	810			0,61	0,37	33,06
11	[10 12]	110	1210			2,61	6,79	747,07
		330						
			logo: 2770		média = 8,39	logo: 1958,79		desvio-padrão (s) = 2,44
			330			330		
			$\bar{x} = \frac{\sum_{i=1}^k c_i F_i}{n}$			$s = \sqrt{\frac{\sum_{i=1}^n (c_i - \bar{x})^2 \times F_i}{n}}$		
			$CV = \frac{s}{\bar{x}} \times 100 \quad (\%)$			CV (%) = 29,02		
						Amostra com baixa dispersão => CV < 50% => a média será tanto mais representativa quanto menor for o CV		



EXERCÍCIO 3

Considere as seguintes estimativas referentes a duas amostras de 50 pneus de marcas diferentes:

Marca 1:

Duração média: 50000 km

Desvio-padrão: 12000 km

Marca 2:

Duração média: 30000 km

Desvio-padrão: 8000 km

Em termos relativos, qual das marcas de pneus apresenta uma maior dispersão relativa da sua duração?



EXERCÍCIO 3

Em termos relativos, qual das marcas de pneus apresenta uma maior dispersão relativa da sua duração?

Marca 1:

Duração média: 50000 km

Desvio-padrão: 12000 km

Marca 2:

Duração média: 30000 km

Desvio-padrão: 8000 km

$$CV = \frac{s}{\bar{x}} \times 100 \quad (\%)$$

Marca 1

CV (%) = 24,0

Marca 2

CV (%) = 26,7

MEDIDAS DE ASSIMETRIA E ACHATAMENTO

- * Forma como se **distribuem os dados horizontalmente**, isto é, indicam-nos o **grau de concentração lateral dos dados**;
- * Tipo de medidas que têm bastante menos aplicação do que as medidas de localização, ou de dispersão;
- * Devem ser tomadas como meros indicadores.

MEDIDAS DE ASSIMETRIA

ASSIMETRIA

* Coeficiente de ASSIMETRIA

Medida que assume o valor **zero** quando a **distribuição de frequências da amostra** é completamente **simétrica** e assume **valores diferentes de zero** (positivos ou negativos) quando a **distribuição não é simétrica**.

- * Atenção que numa amostra é quase impossível observar simetria pura. Por isso, o coeficiente de assimetria assume valores quase sempre diferentes de zero.

Nota: Para se ter uma ideia se a assimetria é relevante deve-se comparar o valor do coeficiente com o erro associado. Se o coeficiente não exceder 2 ou 3 vezes o erro, o seu valor não será muito relevante. No SPSS, o erro associado é fornecido, pelo que se pode realizar esta comparação facilmente.

MEDIDAS DE ASSIMETRIA


ASSIMETRIA

- * Uma distribuição possui assimetria **POSITIVA** (**NEGATIVA**) quando existe uma **concentração de valores** na zona de valores **mais REDUZIDOS** (mais **ELEVADOS**) da amostra.

(Quase) simetria

Coef. ass. = 0

(Coef. ass. ~ 0)




média = mediana = moda

(média $\sim$ mediana $\sim$ moda)

Assimetria positiva


Coef. ass. > 0



moda < mediana < média

Assimetria negativa

Coef. ass. < 0



média < mediana < moda


MEDIDAS DE ASSIMETRIA

ASSIMETRIA

- * Uma distribuição possui assimetria **POSITIVA** (**NEGATIVA**) quando existe uma **concentração de valores** na zona de valores **mais REDUZIDOS** (mais **ELEVADOS**) da amostra.

(Quase) simetria

Frequências repartidas de igual modo
(à esquerda e à direita da média=moda=mediana)




média = mediana = moda

(média ~ mediana ~ moda)

Assimetria positiva


Frequências mais altas encontram-se à esquerda, enquanto que no lado direito, há frequências menores (cauda mais comprida)



moda < mediana < média

Assimetria negativa

Frequências maiores estão no lado direito enquanto que no lado esquerdo, há frequências menores (cauda mais comprida)




média < mediana < moda

MEDIDAS DE ASSIMETRIA

ASSIMETRIA

Coeficiente de *Pearson* (G1)

$$\frac{\bar{x} - Mo}{s} \begin{cases} > 0 & \text{Assimetria positiva} \\ = 0 & \text{Simétrica} \\ < 0 & \text{Assimetria negativa} \end{cases}$$




MEDIDAS DE ASSIMETRIA

ASSIMETRIA


Quando não dispomos da média ou desvio-padrão utilizamos, como **índice de assimetria**, o **Coeficiente de Assimetria de Bowley (g')**:

$$\frac{(Q_3 - Q_2) - (Q_2 - Q_1)}{(Q_3 - Q_1)} \begin{cases} > 0 & \text{Assimetria positiva} \\ = 0 & \text{Simétrica} \\ < 0 & \text{Assimetria negativa} \end{cases}$$




assimétrica **positiva**

A mediana desliza para o lado do Q1, logo $Q_3 - Q_2 > Q_2 - Q_1$




simétrica

Os quartis estão à mesma distância da mediana.



assimétrica **negativa**

A mediana desliza para o lado do Q3, logo $Q_2 - Q_1 > Q_3 - Q_2$



EXERCÍCIO 1C

Nº de viagens (x_i)	Nº de pessoas (F_i)
0	36
1	79
2	85
3	49
4	16
5	23
6	12

Uma empresa do ramo do turismo pretende estudar o número de vezes por ano que os portugueses viajam para fora de Portugal em lazer. Para esse efeito inquiriu 300 pessoas escolhidas aleatoriamente e organizou os dados obtidos na tabela apresentada.

Classifique quanto à (as)simetria.



EXERCÍCIO 1C

Nº de viagens (x_i)	Nº de pessoas (F_i)
0	36
1	79
2	85
3	49
4	16
5	23
6	12

Uma empresa do ramo do turismo pretende estudar o número de vezes por ano que os portugueses viajam para fora de Portugal em lazer. Para esse efeito inquiriu 300 pessoas escolhidas aleatoriamente e organizou os dados obtidos na tabela apresentada.

Classifique quanto à (as)simetria.

média	2,16		
moda	2		
mediana	2		
logo:	média≈mediana=moda		
	Amostra simétrica		



EXERCÍCIO 2C

Um parque temático está a estudar o tempo de espera dos visitantes na compra de bilhete. Foram registados os dados seguintes:

Tempo (em minutos)	Nº de visitantes
[2,4[	20
[4, 6[	40
[6, 8[	70
[8,10[	90
[10,12]	110

Classifique quanto à (as)simetria.

MEDIDAS DE ACHATAMENTO

ACHATAMENTO

Kurtosis (K)

- * Servem para nos **dar a forma como se distribuem os dados verticalmente**
- * Indicam-nos (mede) o **grau de achatamento da curva (distribuição)**
- * Indicativo da intensidade das frequências na vizinhança dos valores centrais
- * Este método consiste na **utilização de medidas de localização**


MEDIDAS DE ACHATAMENTO

ACHATAMENTO

$$\frac{(P_{90} - P_{10})}{(Q_3 - Q_1)} - 1,9 \quad \left\{ \begin{array}{ll} > 0 & \text{Leptocúrtica} \\ = 0 & \text{Mesocúrtica} \\ < 0 & \text{Platicúrtica} \end{array} \right.$$


MEDIDAS DE ACHATAMENTO

ACHATAMENTO



PLATICURTICA

PLATI = PLANA




MESOCURTICA

MESO = MÉDIA



LEPTOCURTICA

**LEPTO = ESTREITO;
ADELGADO**



EXERCÍCIO 1D

Nº de viagens (x_i)	Nº de pessoas (F_i)
0	36
1	79
2	85
3	49
4	16
5	23
6	12

Uma empresa do ramo do turismo pretende estudar o número de vezes por ano que os portugueses viajam para fora de Portugal em lazer. Para esse efeito inquiriu 300 pessoas escolhidas aleatoriamente e organizou os dados obtidos na tabela apresentada.

Classifique quanto ao achatamento.

[illegible]



EXERCÍCIO 2D

Um parque temático está a estudar o tempo de espera dos visitantes na compra de bilhete. Foram registados os dados seguintes:

Tempo (em minutos)	Nº de visitantes
[2,4[	20
[4, 6[	40
[6, 8[	70
[8,10[	90
[10,12]	110

Classifique quanto ao achatamento.

DIAGRAMA DE EXTREMO E QUARTIS - *BOXPLOT*

É uma forma de representação gráfica onde são apresentadas algumas medidas de localização e dispersão




DIAGRAMA DE EXTREMO E QUATIS - *BOXPLOT*

Mínimo da amostra Máximo da amostra
mas não menos de mas não mais de

$$Q_1 - 1.5 \times (Q_3 - Q_1)$$

$$Q_3 + 1.5 \times (Q_3 - Q_1)$$





DIAGRAMA DE EXTREMO E QUATIS - *BOXPLOT*


- Quando não existem *outliers*, os “bigodes” das caixas (*boxplots*) representam o **mínimo** e **máximo** dos dados.
- As caixas de bigodes dão informação sobre:
 - a localização central: mediana;
 - outras localizações: 1º e 3º quartis, mínimo e máximo;
 - dispersão: amplitude e distância interquartil;
 - assimetria: pode ser analisada a partir da posição relativa da mediana na caixa e pelo comprimento dos bigodes.

DIAGRAMA DE EXTREMO E QUATIS - *BOXPLOT*


Assimetria positiva



Simetria




Assimetria negativa





EXERCÍCIO 4

Inquiriu-se um grupo de portugueses quanto ao nº de países já visitados (excluindo Portugal). Com os dados obtidos, construiu-se a seguinte caixa de bigodes:



Determine:

- a) amplitude;
- b) amplitude interquartil;
- c) Comente o coeficiente de assimetria de Bowley.