

Introdução à Inteligência Artificial

1º ano - 1º semestre – 2025/26



“6. Aprendizagem Máquina: Não Supervisionada”

Professor Doutor **Ricardo Vardasca**
ricardo.vardasca@islasantarem.pt

1

Índice


- Aprendizagem Máquina não informadas
 - Redução de Dimensão de Variáveis
 - Agrupamento
 - Associação



2

2

Técnicas de Aprendizagem Máquina




3

3

Aprendizagem Não Supervisionada

- Os dados são agrupados por semelhança (característica comum) ou por ocorrência em simultâneo
- Não há uma pista sobre como deve ser realizado




4

4

Técnicas AM não supervisionadas

- Não existe um objetivo bem definido
- As ferramentas são mais livres na sua aplicação sobre os dados e espera-se que seja descoberta alguma estrutura significativa nos dados



5

5

Redução de dimensão de variáveis

A redução de dimensão das variáveis em análise de dados é uma prática comum e necessária para:

- Simplificação e interpretabilidade.
- Economia de recursos.
- Prevenção de *overfitting*.
- Redução de ruído.
- Estabilidade dos modelos (Redução da Colinearidade).
- Melhoria do desempenho dos modelos.
- Foco em variáveis relevantes.
- Visualização mais clara e compreensível.

6

6

Análise dos componentes principais (PCA)

- A existência de um elevado número de dimensões (atributos) associada a estes conjuntos de dados faz com que visualizá-los graficamente seja impossível.
- Alguns desses atributos tem grande correlação.
- O objetivo é encontrar um meio de condensar a informação contida em vários atributos originais num conjunto menor de atributos estatísticos (componentes) com uma perda mínima de informação.
- Método estatístico não supervisionado que captura a variação dos dados e reduz um grande conjunto de variáveis em variáveis de grupo.
- Deve ser usado quando todos os atributos são independentes entre si, não devendo haver correlação entre eles, os dados devem ter um formato numérico.
- **Maximizar a variância dos pontos de dados.**

7

7

Análise dos componentes principais (PCA)


	Mouse 1	Mouse 2	Mouse 3	Mouse 4	Mouse 5	Mouse 6
Gene 1	10	11	8	3	1	2

If we only measure 1 gene, we can plot the data on a number line...




	Mouse 1	Mouse 2	Mouse 3	Mouse 4	Mouse 5	Mouse 6
Gene 1	10	11	8	3	2	1
Gene 2	6	4	5	3	2.8	1
Gene 3	12	9	10	2.5	1.3	2

If we measured 3 genes, we would add another axis to the graph and make it look "3-D" (i.e. 3-dimensional)



	Mouse 1	Mouse 2	Mouse 3	Mouse 4	Mouse 5	Mouse 6
Gene 1	10	11	8	3	1	2
Gene 2	6	4	5	3	2.8	1



...then we can plot the data on a 2-Dimensional x/y graph.

	Mouse 1	Mouse 2	Mouse 3	Mouse 4	Mouse 5	Mouse 6
Gene 1	10	11	8	3	2	1
Gene 2	6	4	5	3	2.8	1
Gene 3	12	9	10	2.5	1.3	2
Gene 4	5	7	6	2	4	7



8

8

Análise dos componentes principais (PCA)

- Passo 1: Centralizar os Dados
 - Antes de aplicar o PCA, é importante centralizar os dados, i.e. garantir que cada variável tenha uma média de zero.
 - **Como fazer:** Subtrair a média de cada variável de todos os valores dessa variável.
- Passo 2: Calcular a Matriz de Covariância
 - A matriz de covariância mostra como as diferentes variáveis se correlacionam umas com as outras.
 - Se duas variáveis têm uma covariância positiva, significa que, quando uma aumenta, a outra tende a aumentar.
 - Se a covariância é negativa, uma aumenta enquanto a outra tende a diminuir.
 - O PCA usa essa matriz para entender a relação entre as variáveis e determinar as direções de maior variabilidade.
- Passo 3: Calcular os Autovalores e Autovetores
 - A partir da matriz de covariância, calculamos os **autovalores e autovetores**.
 - **Autovetores** são as direções dos componentes principais (as direções em que os dados variam mais).
 - **Autovalores** indicam a quantidade de variância que existe ao longo de cada autovetor.

9

9


Análise dos componentes principais (PCA)

- Passo 4: Ordenar os Componentes Principais
 - Ordenamos os autovetores em ordem decrescente dos seus autovalores.
 - O autovetor com o maior autovalor se torna o **primeiro componente principal**, o que significa que é a direção que captura a maior parte da variação nos dados.
 - O segundo maior autovalor define o **segundo componente principal**, e assim por diante.
- Passo 5: Projetar os Dados nos Novos Componentes
 - Agora, pegamos nos autovetores escolhidos e projetamos os dados originais nesses novos eixos.
 - Isso indica uma versão "compacta" dos dados, mas que ainda mantém a maior parte da informação original.
- Passo 6: Escolher o Número de Componentes
 - O número de componentes a serem usados depende da quantidade de variância que queremos reter.
 - Podemos calcular a proporção da variância explicada por cada componente, que nos ajuda a decidir quantos componentes manter.

10

10

Análise dos componentes principais (PCA)



11

11

Análise dos componentes principais (PCA)

1º centrar os dados:

$$z = \frac{value - mean}{standard deviation}$$

2º computação da matriz de covariância:

$$\begin{bmatrix} Cov(x, x) & Cov(x, y) & Cov(x, z) \\ Cov(y, x) & Cov(y, y) & Cov(y, z) \\ Cov(z, x) & Cov(z, y) & Cov(z, z) \end{bmatrix}$$

3º decomposição dos Eigen (eigenvectors e eigenvalues e identificação dos PCA):

$$v1 = \begin{bmatrix} 0.6778736 \\ 0.7351785 \end{bmatrix} \quad \lambda_1 = 1.284028$$

$$v2 = \begin{bmatrix} -0.7351785 \\ 0.6778736 \end{bmatrix} \quad \lambda_2 = 0.04908323$$

12

12

Análise dos componentes principais (PCA)

4º seleção de características e criação do vetor de características:

$$\begin{bmatrix} 0.6778736 & -0.7351785 \\ 0.7351785 & 0.6778736 \end{bmatrix}$$

$$\begin{bmatrix} 0.6778736 \\ 0.7351785 \end{bmatrix}$$


5º projeção de dados:

$$FinalDataSet = FeatureVector^T * StandardizedOriginalDataSet^T$$



13

13

Análise dos componentes principais (PCA)




However, even a noisy PCA plot like this can be used to identify clusters of data.



14

14


Análise dos componentes principais (PCA)



15

15

Análise dos componentes principais (PCA)





16

16

Análise dos componentes principais (PCA)

	Student1	Student2	Student3	Student4	Student5	Student6
Maths	10.0	11.0	8.0	3.0	1.0	2.0
Physics	6.0	4.0	5.0	3.0	3.2	1.0



	Student1	Student2	Student3	Student4	Student5	Student6
Maths	10.0	11.0	8.0	3.0	1.0	2.0
Physics	6.0	4.0	5.0	3.0	3.2	1.0
History	12.0	9.0	10.0	2.5	1.3	2.0



17

17

Análise dos componentes principais (PCA)



Calculando a média




Removendo a média

18


18

Análise dos componentes principais (PCA)

Medindo a distância dos dados à linha e tentar encontrar a linha que minimize essas distâncias (a linha pontilhada verde).



Tentar encontrar a linha que maximize a distância dos pontos projetados (os pontos laranja) à origem.



19


19

Análise dos componentes principais (PCA)



	Student1	Student2	Student3	Student4	Student5	Student6
Maths	10.0	11.0	8.0	3.0	1.0	2.0
Physics	6.0	4.0	5.0	3.0	3.2	1.0
History	12.0	9.0	10.0	2.5	1.3	2.0

	Student1	Student2	Student3	Student4	Student5	Student6
PC1	-0.561447	-0.646503	-0.451633	0.030548	0.223261	-0.109814
PC2	-0.469342	0.708209	-0.491057	0.139051	-0.131204	0.021715
PC3	-0.614669	0.144279	0.626269	-0.413526	0.195319	-0.000386

Eigen Vector along PC1 : [-2.68191782e+00 1.78779473e+00 5.00135483e-16]
 Eigen Vector along PC2 : [6.04528374e+00 -1.29486389e-01 5.00135483e-16]
 Eigen Vector along PC3 : [-3.36336672e+00 -1.65830834e+00 5.00135483e-16]



PC1 accounts for : 90.22678664377429%
 PC2 accounts for : 9.773213356225702%
 PC3 accounts for : 1.2299057648569933e-30%




20

20

Análise dos componentes principais (PCA)



Person	Height (cm)	Weight (kg)
Alex	145	68
Ben	160	67
Chris	185	69






Feature	Variance
Height	1.11
Weight	1.11
TOTAL	2.22

21

21

Análise dos componentes principais (PCA)




Feature	Variance	Feature	Variance
Height	1.11	PC1	2.22
Weight	1.11	PC2	0.00
TOTAL	2.22	TOTAL	2.22

22

22

Análise dos componentes principais (PCA)






23

23

Análise dos componentes principais (PCA)


	x0	x1	x2	cluster_label
0	-0.366353	1.022466	1.166899	2
1	-1.179214	1.318905	1.047407	2
2	0.346441	-1.360488	-0.417740	1
3	0.507115	0.055279	-0.890964	0
4	-0.185192	0.937566	0.930304	2



24

24

Análise dos componentes principais (PCA)



25

25

Análise dos componentes principais (PCA)

Objetivo	Linearidade	Caraterísticas dados	Iteração	Topologia	Parâmetros entrada	Complexidade computacional	Fraquezas	Transformação
Maximizar variância	Linear	Lida com dados distorcidos	Não	Projeção aleatória	Nr. de componentes	$O(d^2n + n^3)$	Limitado a projeção linear	Decomposição eigen



Vantagens	Desvantagens
Rápido Simples Interpretável	Linear Demasiado simples

26

26

Agrupamento (*Clustering*)

• Medidas de semelhança




27

27

Agrupamento (*Clustering*)

Identificar duas qualidades de dados:


- Significância (expandir o conhecimento do domínio)
- Utilidade (etapa intermediária em um pipeline de dados)
- Dado um conjunto de objetos, colocar os objetos em grupos baseados na similaridade entre eles
- Inerentemente é um problema não definido claramente
- Como agrupar estes animais?



28

28

Agrupamento (*Clustering*)




29

29

Agrupamento (*Clustering*)

- Quantos grupos?



30

30

Agrupamento (*Clustering*)

Quantos grupos?

- Divide os objetos de dados em grupos não sobrepostos
- Escolher como número de grupos (clusters): $\text{SQRT}(N/2)$ - regra prática rápida
- Exemplo: Se tiver 100 pontos de dados, poderá começar com $\text{SQRT}(100/2) = \text{SQRT}(50) = 7$ clusters


31

31

Agrupamento (*Clustering*)

Quantos grupos?

- Técnica do cotovelo (elbow).
- **WCC**: a soma interna dos quadrados mede a soma da diferença quadrada do centro do grupo, um menor valor significa que há menor variação nos dados desse grupo.




32

32

Agrupamento (*Clustering*)

Quantos grupos?


- Técnica do silhueta.
- Indica a homogeneidade de um grupo (quão bem cada objeto está alocado). O índice de Silhueta varia de -1 a 1. Valores próximos a 1 indicam que o objeto possui semelhança com objetos do seu grupo e dessemelhança com objetos de outros grupos.



33

33


Técnicas de Agrupamento (*Clustering*)



34

34

Técnicas de Agrupamento (*Clustering*)





35

35

K-Means


- Tenta minimizar a variação dos pontos de dados dentro de um grupo, maximizando as diferenças entre grupos.
- Não escala bem.



36


36

K-Means



37

K-Means



38




Hierárquico

- Determina as atribuições do cluster ao construir uma hierarquia.
- O **agrupamento aglomerativo** é a abordagem de baixo para cima. Mistura os dois pontos que são mais semelhantes até que todos os pontos tenham sido misturados num único cluster.
- O **agrupamento divisivo** é a abordagem de cima para baixo. Começa com todos os pontos num cluster e divide os clusters menos semelhantes em cada etapa até que apenas pontos de dados únicos permaneçam.
- O nível pretendido define o número de clusters a considerar.

39

39

Hierárquico




40

40

Hierárquico

$$\text{distância}(\text{Cluster}_i, \text{Cluster}_j) = \frac{\sum_{\substack{p_i \in \text{Cluster}_i \\ p_j \in \text{Cluster}_j}} \text{distância}(p_i, p_j)}{|\text{Cluster}_i| * |\text{Cluster}_j|}$$


	I1	I2	I3	I4	I5
I1	0.00				
I2	0.10	0.00			
I3	0.90	0.30	0.00		
I4	0.35	0.40	0.60	0.00	
I5	0.80	0.50	0.70	0.20	0.00



41

41


Hierárquico



42

42

Hierárquico




43

43

GMM – Gaussian Mixture Models

- O modelo de mistura gaussiana usa múltiplas distribuições gaussianas para ajustar dados de formato arbitrário.
- Existem vários modelos gaussianos únicos que atuam como camadas ocultas neste modelo híbrido.
- O modelo calcula a probabilidade de um ponto de dados pertencer a uma distribuição gaussiana específica e esse é o grupo em que ele se enquadra.
- Resolve o problema de grupos com distribuição curva do K-Means.



44

44



GMM – Gaussian Mixture Models

- Passo 1: Inicialização
 - **Número de Clusters (K):** Escolher o número de clusters desejado (ou seja, quantas distribuições Gaussianas devem ser ajustadas aos dados).
- Passo 2: Expectation-Maximization (EM)
 - O GMM usa um algoritmo chamado **Expectation-Maximization (EM)** para ajustar as distribuições Gaussianas aos dados. Este processo é iterativo e consiste em dois passos principais:
 - Passo 2.1: Passo de Expectation (E-step)
 - Neste passo, o GMM calcula a **probabilidade** de cada ponto de dados pertencer a cada um dos clusters (ou componentes Gaussianos).
 - Essas probabilidades são chamadas de **responsabilidades**, que indicam a probabilidade de um ponto i ter sido gerado pelo cluster k .
 - Passo 2.2: Passo de Maximization (M-step)
 - Neste passo, o GMM **recalcula** os parâmetros das distribuições Gaussianas (médias, variâncias e pesos) para melhor se ajustar às responsabilidades calculadas no passo anterior.
- Passo 3: Repetir até Convergência
 - Os passos de E e M são repetidos até que a mudança nos parâmetros seja muito pequena (ou até um número máximo de iterações).
 - **Convergência** é alcançada quando os parâmetros estabilizam, indicando que as distribuições Gaussianas estão bem ajustadas aos dados.
- Passo 4: Classificar os Pontos
 - Depois da convergência, cada ponto de dados é atribuído ao cluster para o qual ele tem a maior responsabilidade.
 - Isso significa que cada ponto será associado ao cluster cuja Gaussianas tem a maior probabilidade de tê-lo gerado.

45

45


GMM – Gaussian Mixture Models



46

46

GMM – Gaussian Mixture Models




47

47

GMM – Gaussian Mixture Models

Expectation-Maximization




48

48

Density-Based Spatial Clustering of Applications with Noise (DBSCAN)

- Bom para encontrar *outliers*.
- Encontra grupos de formato arbitrário com base na densidade de pontos dados em diferentes regiões, encontrando discrepâncias entre as densidades por separação.
- Deve usar-se quando se tem dados representados em formas estranhas.
- Usa 2 parâmetros: o número mínimo de pontos a ser agrupados para que uma área seja considerada de alta densidade (minPts) e a distância usada para determinar se um ponto de dados está na mesma área que outros pontos de dados (eps).
- A correção da escolha dos parâmetros iniciais influencia o seu desempenho.



49

49


DBSCAN

- Passo 1: Escolher os Parâmetros ϵ e min_samples
- Passo 2: Identificar Pontos Core
 - Para cada ponto p do conjunto de dados:
 - Identificar todos os pontos que estão dentro da distância ϵ de p (vizinhança de p).
 - Se o número de pontos na vizinhança de p for maior ou igual a min_samples, então p é um **ponto core**.
- Passo 3: Expandir Clusters a Partir dos Pontos Core
 - Para cada ponto core não visitado:
 - Criar um novo **cluster** e adicionar o ponto core a este cluster.
 - Expandir o cluster:
 - Para cada ponto vizinho do ponto core (dentro do raio ϵ):
 - Se este vizinho for um **ponto core** ainda não visitado, adicionar todos os seus vizinhos ao cluster.
 - Se for um **ponto fronteira**, simplesmente adicionar ao cluster (mas não expandir a partir dele).
 - Continuar a expansão até que todos os pontos vizinhos estejam atribuídos ao cluster.
- Passo 4: Identificar Pontos de Ruído
 - Após a expansão dos clusters, alguns pontos podem permanecer não atribuídos a nenhum cluster.
 - Estes pontos são marcados como **outliers** ou **ruído**.
 - São pontos que não têm vizinhos suficientes para serem pontos core e não estão dentro da vizinhança de um ponto core.
- Passo 5: Finalização
 - Ao final do processo, todos os pontos do conjunto de dados serão rotulados como pertencentes a um cluster específico ou como ruído.
 - Cada cluster é formado por um grupo de pontos core conectados e seus pontos fronteira.

50


50

Density-Based Spatial Clustering of Applications with Noise (DBSCAN)



51

Density-Based Spatial Clustering of Applications with Noise (DBSCAN)



52

Comparação

Método	Parâmetros	Tamanho dos grupos (clusters)	Número de grupos (clusters)	Geometria
K-Means	Num. Grupos	Normal	Não muitos	Plana
Hierárquico	Num. Grupos, tipo ligação e distância	Distinto	Muitos	Hierárquico
GMM	Num. Grupos	Não escalável	Não escalável	Plana
DBSCAN	Tamanho da vizinhança	Distintos	Médio	Não plana

53

53

Regras de associação

- Métodos não supervisionados que permitem descobrir relações (padrões) entre atributos (variáveis) de grandes conjuntos de dados
- Normalmente envolvem o uso de algoritmos para analisar os dados e identificar os relacionamentos
- As regras resultantes são frequentemente expressas na forma de declarações "se-então", onde a parte "se" representa o antecedente (a condição que está sendo testada) e a parte "então" representa o consequente (o resultado que ocorre se a condição for testada)
- É uma técnica importante na análise de dados porque permite descobrir padrões ou relacionamentos dentro dos dados que podem não ser imediatamente aparentes
- Ao identificar associações entre variáveis, ajuda a compreender as relações entre diferentes variáveis e como essas variáveis podem estar relacionadas entre si

54

54

Apriori

Algoritmo projetado para identificar associações frequentes entre itens, o que pode ser útil para entender padrões.

Funcionamento:

- **Passo 1: Geração de Itemsets de 1 Item (Itemsets de 1ª Ordem):** Começa por identificar todos os itens individuais presentes no conjunto de dados e contar a frequência de cada item. Isso cria o conjunto de itemsets de 1ª ordem, que consiste em todos os itens individuais e suas contagens.
- **Passo 2: Geração de Itemsets de 2ª Ordem:** Combina todos os pares possíveis de itens a partir dos itemsets de 1ª ordem. De seguida, examina o conjunto de dados para contar a frequência de cada par de itens gerado. Aqueles que atingem um nível mínimo de suporte (um valor pré-definido que determina o que é considerado "frequente") são mantidos.
- **Passo 3: Geração de Itemsets de kª Ordem (k > 2):** O processo é repetido para geração de itemsets de ordem superior (k > 2). Nesse processo, itemsets de kª ordem são gerados combinando os itemsets frequentes de (k-1)ª ordem. O suporte é novamente calculado para cada itemset gerado e aqueles que atendem ao limite de suporte mínimo são mantidos.
- **Passo 4: Geração de Regras de Associação:** Assim que todos os itemsets frequentes tenham sido identificados, as regras de associação são geradas a partir desses itemsets. As regras de associação geralmente têm a forma "se {A} então {B}", onde A e B são conjuntos de itens, e a confiança e o suporte da regra são calculados. A confiança mede a probabilidade de que a regra seja verdadeira, dado que o itemset A ocorreu. O suporte mede a frequência com que a regra é verdadeira.
- **Passo 5: Filtro de Regras:** As regras de associação são frequentemente filtradas com base em critérios como suporte mínimo e confiança mínima. Isso ajuda a identificar as regras mais relevantes e significativas.

55

55

Apriori

- **Suporte** é simplesmente o número de transações que incluem todos os itens na parte antecedente e conseqüente da regra. Assim, para uma determinada regra de associação $\{X\} \Rightarrow \{Y\}$, o suporte da regra mede o número total de registos de transação que contêm os conjuntos de itens X e Y .

$$\text{Suporte } (X \rightarrow Y) = \frac{\text{Frequência de } X \text{ e } Y}{\text{Total de } T}$$

56

56

Apriori

- A **confiança** do conjunto de itens frequentes corresponde ao rácio entre o número de transações em que X e Y ocorrem simultaneamente e a quantidade de transações em que o item X ocorre. Em termos gerais a confiança mede a probabilidade condicional de ocorrer Y dado que ocorreu X.

$$\text{Confiança } (X \rightarrow Y) = \frac{\text{supp } (X \cup Y)}{\text{supp } (X)}$$

57

57

Apriori

- **Lift** ou coeficiente de interesse é uma das medidas mais utilizadas para avaliar dependências entre o antecedente e o conseqüente da regra. A sua variação é entre zero e infinito e tem uma leitura muito simples: quanto maior o seu valor, mais interessante é a regra, pois maior é a dependência entre os itens que a constituem.
- Dada uma regra $X \rightarrow Y$, esta medida indica que quanto mais frequente se torna Y quando X ocorre.

$$\text{Lift}(X \rightarrow Y) = \text{confiança}(X \rightarrow Y) / \text{suporte}(Y) = \frac{\text{suporte}(X \cup Y)}{\text{suporte}(X) \times \text{suporte}(Y)}$$

58

58

Apriori

Se $Lift(X \rightarrow Y) = 1$, então X e Y são independentes

Se $Lift(X \rightarrow Y) > 1$, então X e Y são positivamente dependentes

Se $Lift(X \rightarrow Y) < 1$, então X e Y são negativamente dependentes

O lift possui como característica o fato de ser uma medida simétrica, ou seja: $Lift(X \rightarrow Y) = Lift(Y \rightarrow X)$

Items frequentes: Suporte {item} $\geq$ Suporte Mínimo

Items raros: Suporte {item} $\leq$ Suporte Máximo

59

59

Apriori

- Exemplo:



	Café	Pão	Bolo	Leite	Pudim
1	1	0	1	0	0
2	1	1	1	0	0
3	0	0	1	0	1
4	1	1	0	1	0
5	0	0	0	0	1
6	1	0	1	0	0
7	0	0	1	1	1
8	1	1	0	0	0
9	1	1	1	0	0
10	1	0	1	0	0

60

60

Apriori

• Exemplo:

Pedido 1	 
Pedido 2	  
Pedido 3	  
Pedido 4	  
Pedido 5	 
Pedido 6	  
Pedido 7	  
Pedido 8	  
Pedido 9	  
Pedido 10	 

$$\text{Support } \{ X \} = \frac{\text{Número de transações em que X aparece}}{\text{Número Total de Transações}}$$

$$\text{Support } \{ \text{Café} \} = \frac{4}{10} = 40\%$$

$$\text{Confidence } \{ X \rightarrow Y \} = \frac{\text{Número de transações em que X e Y aparecem}}{\text{Número de transações em que X aparece}}$$

$$\text{Confidence } \{ \text{Café} \rightarrow \text{Pão} \} = \frac{2}{7} \approx 28.57\%$$

$$\text{Lift } \{ X \rightarrow Y \} = \frac{\text{Support } \{ X, Y \}}{\text{Support } \{ X \} \cdot \text{Support } \{ Y \}}$$

$$\text{Lift } \{ \text{Café} \rightarrow \text{Pão} \} = \frac{4/10}{7/10 \cdot 4/10} \approx 1.43$$

61

61

Apriori

• Exemplo: **support mínimo = 0.3 e um confidence mínimo = 0.4**

items	support	length
{Café}	0.7	1
{Bolo}	0.7	1
{Pão}	0.4	1
{Pudim}	0.3	1
{Leite}	0.2	1

items	support	length
{Café, Bolo}	0.5	2
{Café, Pão}	0.4	2
{Pão, Bolo}	0.2	2
{Bolo, Pudim}	0.2	2
{Pão, Pudim}	0.1	2
{Café, Pudim}	0.0	2

items	support	length
{Café, Bolo, Pão}	0.2	3

items	support	length
{Café, Bolo}	0.5	2
{Café, Pão}	0.4	2

items	confidence
{Pão} -> {Café}	1
{Café} -> {Bolo}	0,714
{Bolo} -> {Café}	0,714
{Café} -> {Pão}	0,571

items	lift
{Pão} -> {Café}	1,429
{Café} -> {Bolo}	1.02
{Bolo} -> {Café}	1.02
{Café} -> {Pão}	1,429

62

62

Apriori

• Exemplo:

Transaction ID	Items bought
T1	🍷 🍷 🍷
T2	🍷 🍷 🍷 🍷
T3	🍷 🍷 🍷 🍷
T4	🍷 🍷 🍷 🍷
T5	🍷 🍷 🍷

Minimum support $\geq 60\%$ (3/5)

1-Itemset	Support
🍷	4/5
🍷	4/5
🍷	4/5
🍷	3/5
🍷	1/5

2-Itemset	Support
🍷 🍷	3/5
🍷 🍷	2/5
🍷 🍷	3/5
🍷 🍷	3/5


3-Itemset	Support
🍷 🍷 🍷	2/5
🍷 🍷 🍷	2/5
🍷 🍷 🍷	2/5
🍷 🍷 🍷	1/5

2-Itemset	Support	Confidence
🍷 $\Rightarrow$ 🍷	3/5	100%
🍷 $\Rightarrow$ 🍷		75%
🍷 $\Rightarrow$ 🍷	3/5	75%
🍷 $\Rightarrow$ 🍷		75%
🍷 $\Rightarrow$ 🍷	3/5	75%
🍷 $\Rightarrow$ 🍷		75%
🍷 $\Rightarrow$ 🍷	3/5	75%
🍷 $\Rightarrow$ 🍷		75%

63


Apriori

TID	Items
1	ABC
2	ABCD
3	BCE
4	ACDE
5	DE




64

Apriori



65

Apriori



66

Frequent Pattern Growth (FP-Growth)

Desenvolvido para superar as limitações do Apriori em termos de eficiência computacional, especialmente quando se lida com conjuntos de dados grandes ou esparsos.

Funcionamento:

- **Passo 1: Construção da Estrutura de Dados de Árvore de Prefixo (FP-Tree):** Começa pela construção de uma estrutura de dados chamada "FP-Tree." Essa árvore é uma representação compacta dos itens frequentes do conjunto de dados. Os passos para criar a árvore são os seguintes:
 - a. **Contagem de Frequência:** Primeiro, analisa o conjunto de dados para contar a frequência de cada item. Isso ajuda a identificar os itens frequentes.
 - b. **Ordenação dos Itens:** Os itens são ordenados em ordem decrescente de frequência. Ajudando a priorizar os itens mais frequentes na construção da árvore.
 - c. **Construção da Árvore:** A árvore é construída começando com um nó raiz. Para cada transação no conjunto de dados, os itens são adicionados à árvore de acordo com a ordem de frequência. A cada nível da árvore, os itens são organizados em nós-filho, com base na ordem de frequência.
- **Passo 2: Extração de Padrões de Associação:** Uma vez que a árvore FP tenha sido construída, utiliza um processo de recursão para extrair padrões de associação frequentes. Isso é feito através da exploração da estrutura da árvore para identificar combinações de itens frequentes.
- **Passo 3: Criação de Regras de Associação:** Depois de identificar os conjuntos de itens frequentes, gera regras de associação a partir desses conjuntos. As regras seguem a forma padrão "se {A} então {B}" e incluem medidas de suporte e confiança para avaliar sua relevância.

67


67

Frequent Pattern Growth (FP-Growth)

Step 2: Construct the FP-tree from the above data

TID	Items	(Ordered) Frequent Items
1	A, B	A, B
2	B, C, D	B, C, D
3	A, C, D, E	A, C, D, E
4	A, D, E	A, D, E
5	A, B, C	A, B, C


Item	Head of node-link
A	
B	
C	
D	
E	



68

68

Frequent Pattern Growth (FP-Growth)




69

69

Frequent Pattern Growth (FP-Growth)


Mínimo suporte = 0.3



70

70

Frequent Pattern Growth (FP-Growth)



71

Equivalence Class Transformation (ECLAT)

Lida com conjuntos de dados esparsos e é uma alternativa eficaz ao Apriori

Funcionamento:

- **Passo 1: Construção da Estrutura de Índice Vertical:** Começa por construir uma estrutura de índice vertical a partir dos dados. Essa estrutura de índice é usada para acelerar a identificação de itemsets frequentes.
 - Criação de Listas de Transações: Para cada item presente nos dados, o algoritmo cria uma lista de transações que contém os identificadores das transações em que esse item aparece.
 - Ordenação das Listas: As listas de transações são ordenadas com base no tamanho (número de transações) em ordem decrescente. Itens mais frequentes aparecerão nas listas com mais transações.
- **Passo 2: Geração de Itemsets Frequentes:** Utiliza uma abordagem recursiva para identificar itemsets frequentes.
- **Passo 3: Criação de Regras de Associação:** depois de identificar os itemsets frequentes, gera regras de associação a partir desses itemsets. Seguem a forma padrão "se {A} então {B}" e incluem medidas de suporte e confiança para avaliar sua relevância.

72

Equivalence Class Transformation (ECLAT)

Mínimo soporte = 2

ID	Items bought
100	A, B, E
200	B, D
300	B, C
400	A, B, D
500	A, C
600	A, B, C

Items	ID list
A	100, 400, 500, 600
B	100, 200, 300, 400, 600
C	300, 500, 600
D	200, 400,
E	100

Items	ID list
A	100, 400, 500, 600
B	100, 200, 300, 400, 600
C	300, 500, 600
D	200, 400,
E	100

Itemlist	ID list
A, B	100, 400, 600
A, C	500, 600
A, D	400
B, C	300, 600
B, D	200, 400
C, D	--

73

73

Equivalence Class Transformation (ECLAT)

Itemlist	ID list
A, B	100, 400, 600
A, C	500, 600
A, D	400
B, C	300, 600
B, D	200, 400
C, D	--

Itemlist	ID list
A, B	100, 400, 600
A, C	500, 600
B, C	300, 600
B, D	200, 400

Items	ID list
A, B, C	600
B, C, D	--

Itemlist
A, B
A, C
B, C
B, D

74

74

Comparação

Algoritmo	Eficiência de tempo	Lidar com conjuntos de dados densos e esparsos	Suporte de itemsets infrequentes	Necessidade de ordenação de dados	Facilidade de implementação
APRIORI	Ineficiente por poder gerar grande número de candidatos	Lida bem	Encontra facilmente, pode revelar lentidão em conjuntos muito grandes	Os dados necessitam de ser pré ordenados de acordo com o suporte dos itens	Fácil de implementar e entender
FP-Growth	Eficiente por estrutura em árvore	Lida bem, no entanto mais eficiente em conjuntos esparsos	Não é eficaz por virtude de se focar com itemsets frequentes	Não requer ordenação prévia	Mais complexo – árvore de prefixo
ECLAT	Eficiente em dados esparsos em virtude de usar estrutura de índice vertical	Mais eficiente em conjuntos esparsos que densos	Bom, especialmente em conjuntos esparsos	Não requer ordenação prévia, sendo eficiente em conjuntos de dados não ordenados	Mais complexo – estrutura de índice vertical

Conjunto de Dados Densos: a maioria dos elementos ou valores está presente e não é nulo.

Conjunto de Dados Esparsos: a maioria dos elementos ou valores está ausente, ou seja, são nulos.

75

75

Comparação

Algoritmo	Vantagens	Desvantagens
APRIORI	Facilidade de implementação Flexibilidade de cenários de aplicação Suporte a itemsets infrequentes	Ineficiência em conjuntos de dados muito grandes Requer ordenação de dados Dificuldade em lidar com conjuntos de dados esparsos
FP-Growth	Eficiência Não requer ordenação Lida bem com conjuntos de dados esparsos	Complexidade de implementação Limitado na identificação de itemsets infrequentes
ECLAT	Eficiência em Conjuntos de Dados Esparsos Identificação de Itemsets Infrequentes Não Requer Ordenação	Complexidade de Implementação Ineficiência em conjuntos de dados densos

Conjunto de Dados Densos: a maioria dos elementos ou valores está presente e não é nulo.

Conjunto de Dados Esparsos: a maioria dos elementos ou valores está ausente, ou seja, são nulos.

76

76