

Introdução à Inteligência Artificial

1º ano - 1º semestre – 2025/26


“8. Aprendizagem Máquina: Supervisionada (Regressão/previsão)”

Professor Doutor **Ricardo Vardasca**
ricardo.vardasca@islasantarem.pt

1

Índice


- Regressão (Previsão)
 - Correlações entre variáveis
 - Regressão linear simples
 - Regressão linear multivariável
 - Regressão polinomial
 - Avaliação de regressão



2

2

Técnicas de Aprendizagem Máquina



3


3

Classificação $\neq$ Regressão (Previsão)

- Imagine que é um vidente e recebe dois clientes:
- Um pergunta: Vou-me casar no próximo ano?
- O outro pergunta: Quantos anos vão passar até que eu me case?

Classificação

Regressão (Previsão)




4

4

A ideia chave

- Ambos são tipos de aprendizagem supervisionada
- Ambos aprendem de exemplos
- Mas o que preveem é diferente



5

5

Regressão (Previsão)

- Objetivo: prever números contínuos
- Uma app de meteorologia dizer: “Amanhã vão estar 24° C!”
- Uma app de imobiliário dizer: “Esta casa vale 300.000,00 EUR”




6

6

Classificação ≠ Regressão (Previsão)

- A grande diferença -> Ambos são preditores, mas pensam de forma diferente!
- Classificação ordena as coisas em caixas, ex: um tapete transportador inteligente largar as bolas em caixas de diferentes categorias
- Regressão não usa caixas, mede! Ex: usa o mesmo tapete, mas posiciona as bolas numa linha numérica para dizer “Quanto” ou “Quão alto”




7

7

Classificação ≠ Regressão (Previsão)

- Como o cérebro funciona?
- Classificação: calcula as probabilidades de cada categoria, ex: “estou 92% certo que é um cão e 8% que é um gato, vamos escolher o cão!”
- Regressão: diretamente indica um número, ex: “A previsão é 18,7 ° C”, preciso, não apenas sim/não




8

8

Correlações entre variáveis

- Mede o grau de associação ou relação entre duas variáveis numéricas.
- Indica se as variáveis tendem a aumentar ou diminuir juntas (correlação positiva), ou se uma aumenta enquanto a outra diminui (correlação negativa).
- Ferramenta fundamental na análise estatística, pois permite entender como variáveis podem estar relacionadas e se uma pode ser usada para prever ou explicar a outra.




$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 (y_i - \bar{y})^2}}$$

9

9

Regressão

- Técnica estatística e de aprendizagem máquina supervisionada (data mining) usada para modelar e analisar a relação entre uma variável dependente (variável alvo) e uma ou mais variáveis independentes (variáveis preditoras).
- O objetivo principal é **prever ou estimar valores da variável dependente** com base nos valores das variáveis independentes, além de **quantificar a força e a natureza da relação** entre essas variáveis.



10


10

Regressão linear simples

- Modela a relação entre uma variável dependente contínua e uma única variável independente.
- A relação entre as variáveis é assumida como linear, sendo representada por uma linha reta na fórmula:

$$y = b_0 + b_1 \cdot x + \varepsilon$$

onde y é a variável dependente, x é a variável independente, b_0 é a interceção da reta, b_1 é o coeficiente da variável x, e ε é o termo de erro.



- Ex: Estimar o preço de uma casa com base na sua área em m².

11

11

Regressão linear simples


- A soma dos quadrados dos desvios verticais dos pontos:

$$f(\beta_0, \beta_1) = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$$

- Uma reta é razoável se as distâncias verticais (desvios) dos pontos analisados em relação à reta são pequenas

$$\frac{\partial f(\beta_0, \beta_1)}{\partial \beta_0} = \sum 2(y_i - \beta_0 - \beta_1 x_i)(-1) = 0$$

$$\frac{\partial f(\beta_0, \beta_1)}{\partial \beta_1} = \sum 2(y_i - \beta_0 - \beta_1 x_i)(-x_i) = 0$$



12

12

Regressão linear simples

Componentes:


- **Variável dependente (y):** a variável que queremos prever ou explicar. É o alvo ou output do modelo.
- **Variáveis independentes (x):** variáveis que têm algum tipo de influência sobre a variável dependente. Servem como preditores ou inputs.
- **Coeficientes:** valores que representam o impacto de cada variável independente sobre a variável dependente. Em regressão linear, por exemplo, eles são ajustados para minimizar a diferença entre os valores preditos e os valores reais de y.
- **Erro residual (ϵ):** a diferença entre o valor predito pelo modelo e o valor real da variável dependente. Em regressão linear, o objetivo é minimizar a soma dos quadrados dos erros (SSE) para ajustar o modelo.

13

13

Regressão linear simples

- Classificação




14

14

Regressão linear simples

- Problemas




15

15

Regressão linear simples

- Exemplo:
 - Relação entre horas de estudo e notas
 - Qual a nota prevista para alguém que estuda 9.25h por dia?



$$Y = 9.78 \cdot X + 2.48$$

Para 9.25 horas de estudo todos os dias a nota prevista com o modelo é 93.69 %

16



16

Regressão linear multivariável

- Estende da regressão linear para a situação em que tem mais de uma variável independente.

$$y = b_0 + b_1 \cdot x_1 + b_2 \cdot x_2 + \dots + b_n \cdot x_n + \varepsilon$$

- A relação é dada por:



- Ex: Estimar o preço de uma casa com base em múltiplas variáveis, como área, localização e número de quartos.

17

17

Regressão linear multivariável

Problemas:

- Multicolinearidade - fenómeno em modelos de regressão múltipla em que uma ou mais variáveis independentes estão intimamente relacionadas entre si, existe um alto grau de correlação entre uma ou mais variáveis explicativas.
 - Correlações acima de 0.7 ou 0.8 (em termos absolutos) entre variáveis independentes podem indicar multicolinearidade.
 - Variance Inflation Factor (VIF) mede o quanto a variância de um coeficiente de regressão está inflada devido à colinearidade com outras variáveis.

$$VIF_j = \frac{1}{1 - R_j^2}$$

VIF _j	Interpretação
=1	Nenhuma correlação entre as variáveis
>1 e <5	Correlação moderada, aceitável
>= 5	Forte multicolinearidade

- Solução: Remover variáveis redundantes, reduzir a dimensão de variáveis ou aplicar regularização.


18

18

Regressão linear multivariável

- Exemplo

- Relação entre **IMC**, **calorias**, ser **fisicamente ativo** e **sexo**
- Qual deve ser o IMC de um homem fisicamente ativo que ingere 5000 calorias por dia?



IMC = 15.0 + 1.5 (calorias) + 1.6 (se masculino) - 4.2 (se ativo), R^2 múltiplo = 0.89

R: 24


19

19


Regressão Polinomial

- Extensão da regressão linear onde a relação entre a variável dependente e a independente é modelada como uma função polinomial.
- Útil para dados com curvatura que não se ajustam bem a uma linha reta.

Simple linear model



Polynomial model



Polynomials	Form	Degree	Examples
Linear Polynomial	$p(x): ax+b, a \neq 0$	Polynomial with Degree 1	$x + 6$
Quadratic Polynomial	$p(x): ax^2+bx+c, a \neq 0$	Polynomial with Degree 2	$3x^2-4x+7$
Cubic Polynomial	$p(x): ax^3+bx^2+cx, a \neq 0$	Polynomial with Degree 3	$2x^3+3x^2+4x+6$

- Ex: Modelar a trajetória de um objeto que segue uma curva parabólica.



20

20

Regressão Polinomial

Componentes:

- Grau
- Coeficiente
- Termo principal
- Coeficiente principal
- Termo constante



21

21


Regressão Polinomial

- Exemplo:
- Relação entre **nível de cargo** e **salário**.
- Qual deve ser o salário de alguém com nível de cargo 6,5?

$$Y = 80878.79 \cdot X + -195333.33$$

salarydata

Position	Level	Salary
Business Analyst	1	45000
Junior Consultant	2	50000
Senior Consultant	3	60000
Manager	4	80000
Country Manager	5	110000
Region Manager	6	150000
Partner	7	200000
Senior Partner	8	300000
C-level	9	500000
CEO	10	1000000




R: 158862.45

22

22

Avaliação de regressão

- Coefficient of Determination or R-Squared (R^2)
- Mean Absolute Error (MAE)
- Mean Squared Error (MSE)
- Root Mean Squared Error (RSME)



$$R^2 = 1 - (RSS/TSS)$$

$$RSS = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$$

$$TSS = \sum (y_i - \bar{y}_i)^2$$

$$MAE = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|$$

$$MSE = \frac{1}{N} \sum_i (Y_i - \hat{y}_i)^2$$

$$RMSE = \sqrt{\frac{RSS}{n}} = \sqrt{\sum_{i=1}^n (y_i^{Actual} - y_i^{Predicted})^2 / n}$$

23

23

Resumo

Tipo	Descrição	Quando usar	Vantagem	Desvantagem
Linear simples	Modela a relação linear entre uma variável independente (X) e uma dependente (Y).	Quando há uma única variável explicativa e uma relação linear.	Simplicidade e interpretabilidade.	Limitação a uma única variável e relação linear; não se ajusta a dados não lineares.
Multivariável	Extensão da regressão linear simples com múltiplas variáveis independentes.	Quando há várias variáveis explicativas.	Permite identificar a influência de múltiplas variáveis.	Problemas de multicolinearidade; aumento de complexidade com o número de variáveis.
Polinomial	Regressão linear estendida com termos de maior ordem (quadráticos, cúbicos).	Quando a relação entre variáveis é não linear e polinomial.	Pode identificar relações não lineares entre variáveis.	Maior risco de overfitting e complexidade aumenta rapidamente com o grau do polinômio.

24

24

Resumo

Principais Diferenças:

- **Simple vs Multivariável:** a regressão linear simples trata de uma única variável explicativa, enquanto a multivariável envolve múltiplas variáveis, o que aumenta a complexidade e a capacidade explicativa do modelo.
- **Polinomial:** amplia a regressão linear, adicionando termos não lineares que permitem capturar relações mais complexas entre variáveis.

25

25

Resumo

Quando usar o quê?

- Se a saída for baseada em rótulo -> Classificação
- Se for numerica ou continua -> Regressão
- Pensa:
 - Spam ou Não Spam -> Classificação
 - Preço de uma casa -> Regressão




26

26

Sumário

Caraterística	Classificação	Regressão
Saída	Categoria	Número
Exemplos	Deteção de Spam, predição de doença	Preço, Temperatura, Idade
Algoritmos	Regressão Logística, Random Forest	Regressão Linear, SVR
Tipo de questão	“Qual?”	“Quanto?”



27